面向无人机群多智能体强化学习的对抗仿真平台与攻防验证

刘双成[1]，李思民[1*]，李海南[2]，修敬乔[1]，刘艾杉[1,2]，刘祥龙[1,2,3]

（1. 北京航空航天大学复杂关键软件环境全国重点实验室，北京 100191；
2. 合肥综合性国家科学中心数据空间研究院，合肥 230000；
3. 中关村实验室，北京 100094）

摘要：随着深度学习的函数拟合能力不断增强，研究人员将深度学习引入到强化学习中，多智能体强化学习研究的核心是如何使一组智能体在协作中学习并实施有效的策略。通过考虑智能体之间的相互作用，使得智能体具备更通用的策略和处理不同任务的能力，当前在包括无人机群等一系列复杂的决策任务上应用广泛。然而，使用多智能体强化学习训练得到的无人机群模型在部署时会面临环境的动态变化、输入的不确定性甚至是恶意攻击，表现出模型不鲁棒的问题。文章基于 AirSim 仿真环境，设计了一个无人机群对抗环境，采用基于规则的方法，将多智能体强化学习算法 MAPPO 适配到无人机群中，研究得到智能的无人机群模型，并深入探讨了其在个体和集体层面的行为模式。基于上述研究成果，文章提出面向无人机群的攻击框架，包含五种无人机群鲁棒性测试方法覆盖基于策略、观测和奖励函数的三种攻击算法以及基于少数群体和多数群体两种攻击算法，较为全面地覆盖了无人机群所面临的威胁。文章集成无人机群对抗环境、训练算法和攻击算法构建无人机群对抗平台并基于该平台进行实验。结合实验的可视化结果，文章分析了遭受五种攻击算法时无人机群模型的异常行为，证实了无人机群模型可能暴露的脆弱性问题，为提高无人机群模型鲁棒性的研究奠定了基础。

关键词：无人机群；强化学习；对抗攻击；仿真环境

中图分类号：V27 **文献标识码：**A

Simulation Platform and Attack and Defense Verification for Adversarial Multi-Agent Reinforcement Learning in UAV Swarms

LIU Shuangcheng[1], LI Simin[1*], LI Hainan[2], XIU Jingqiao[1], LIU Aishan[1,2], LIU Xianglong[1,2,3]

(1. State Key Laboratory of Software Development Environment (SKLSDE), Beihang University, Beijing 100191, China;
2. Institute of Data Space, Hefei Comprehensive National Science Center, Hefei 230000, China;
3. Zhongguancun Laboratory, Beijing 100094, China)

Abstract: With the increasement of the fitting ability in deep learning, researchers introduce deep learning into reinforcement learning, the key for multi-agent reinforcement learning (MARL) is how to enable a group of intelligent agents to learn and implement effective strategies in collaboration. The intelligent agents have the ability of more universal strategies and different tasks by the interactions between intelligent agents, nowadays, it is widely applied in a series of complex strategies such as unmanned aerial vehicle (UAV) swarms. However, the MARL is used to obtain the models of UAV swarms, and then facing the problems of the dynamics changes in the environment during deployment, input uncertainty, malicious attacks and non-robustness models. On the basis of the AirSim simulation platform, a UAV swarm combat scenario is designed, the multi-agent reinforcement learning algorithm MAPPO is adapted to the UAV swarms by the rule-based method, which achieves the intelligent models of UAV swarms, and deeply discusses its behaviors in the individual and group levels. Based on the above results, an adver-

基金项目：科技创新 2030 重大项目（2022ZD0116405）；国家自然科学基金项目（62206009）。

引用格式：刘双成，李思民，李海南，等. 面向无人机群多智能体强化学习的对抗仿真平台与攻防验证［J］. 网络空间安全科学学报，2023，1（2）：93-111.

sarial framework of UAV swarms is proposed, including five novel testing algorithms for UAV swarm robustness, it involves three attack algorithms of the policy, observation, and reward-based function, alongside two unique strategies with the minority attack and majority attack, thereby comprehensively enveloping the threats faced by UAV swarms. A UAV swarm platform is built by integrating the environment of UAV swarms, training algorithms, and attack algorithms, the experiments are conducted on this platform. The visualization results of the test are combined to analyze the abnormal responses of UAV swarm models with five attack algorithms, it is verified the fragility inherent in UAV swarm operations, and provides a basis for improving the robustness of UAV models.

Keywords: UAV swarms; reinforcement learning; adversarial attack; simulation environment

0 引言

多智能体系统是由同一个环境中的多个交互智能体组成的系统，常用于解决单智能体难以处理的问题。无人机群作为一种典型的多智能体系统，近年来在飞行表演、快递物流、精准农业、城市交通、灾害救援、全景拍摄、环保检测、交通监视和电力巡检等领域大显身手，在世界范围内渐趋流行。

当前，科研人员正在积极尝试利用强化学习算法使无人机群具备一定的智能水平。强化学习的本质是解决智能体在与环境交互过程中学习某种策略以最大化奖励或实现特定目标的问题。在无人机群控制领域，强化学习相对于监督学习具有以下优势：（1）自主性：强化学习是一种自主学习方法，无人机群可以自行探索环境，自主地选择动作和策略，相比于需要大规模数据集的监督学习，强化学习的奖励函数更容易设计，适合解决诸如无人机群等复杂的决策问题。（2）适应性：强化学习可以学习到复杂的策略，能够适用于不同的场景和任务。监督学习通常只能处理有限的场景和任务，强化学习则可以在未知环境中不断试错，逐渐适应和优化策略。（3）协作性：在无人机群控制中，不同的无人机之间需要协作，共同完成复杂的任务。随着深度学习的兴起，融合深度神经网络的多智能体强化学习在策略游戏[1]、集群控制[2]等领域取得了较大突破，并在安全监测[3]、洪水检测[4]、抢险救灾[5]等关键的领域发挥了重大作用。在无人机群控制领域，由美国高级研究计划局（DARPA）主导的OFFSET 计划[6]已经能够使用智能算法控制数百架无人机进行侦察、作战等任务。值得一提的是，Nature 发文指出，使用强化学习控制的无人机已经可以在无人机竞速赛中超越人类冠军选手，展示了强化学习强大的适应能力与学习能力[7]。研究多智能体强化学习在无人机群上的应用有极高的研究价值和现实意义。

然而，在真实世界中使用多智能体强化学习训练得到的无人机群模型是非常脆弱的。攻击者可以篡改无人机群模型中的数据，如传感器数据、地图数据等，导致无人机群的决策出现偏差或者误判。攻击者可能通过网络攻击来窃听无人机群系统的通信，获取无人机群的决策信息，或者通过发射干扰信号干扰无人机群系统的通信，破坏整个无人机群的行动。攻击者还可能通过无人机群系统的软件漏洞或者后门攻击[8-10]无人机群模型，从而控制无人机群的行动或窃取敏感的隐私信息。

无人机群模型不安全的根源来自于多智能体强化学习的脆弱性，可能在多个阶段（训练阶段和测试阶段）和多个角度（状态空间、动作空间、奖励函数和环境转移概率）被攻击。攻击者可以从状态空间入手，使用对抗样本[11-14]扰乱智能体的观测，或者从动作空间入手，直接控制多智能体系统中某一个智能体的行为[15]。此外，攻击者可以在训练阶段对于强化学习模型的训练样本进行“投毒”，也可以在测试阶段对于强化学习进行对抗攻击，改变测试时的环境，干扰智能体正常运作。综上，多智能体强化学习模型本身并不鲁棒，但是由于多智能体强化学习在无人机群之类的安全攸关场景中有着广泛的前景，提高多智能体强化学习模型的鲁棒性愈发重要。针对广泛部署的无人机群模型，构建全方位的无人机群对抗平台并研究各种攻击方式的机理，具有重要的意义。

本文首先基于 AirSim[16]开源仿真环境设计一个无人机群的对抗仿真环境，在接近物理环境和真实场景的同时，尽可能地保持普适性和可扩展性。基于该环境，本文部署多智能体强化学习算法进行无人机群模型的训练，并研究多智能体强化学习攻击算法的机理。本文开发的平台可以作为无人机群的博弈演练场，可以作为无人机群模型鲁棒性的测试床，为更好地提升无人机群模型的鲁棒性提供一定的便利。

1 相关技术研究现状

1.1 无人机群训练算法

无人机群的任务执行和交互过程由复杂而精密

的系统构成，其复杂行为的背后是一系列基于多智能体博弈的策略学习与优化，使用单智能体算法训练的无人机群由于缺少合作策略的引导，容易探索到自私策略或是局部的最优策略，不符合无人机群的功能设想。

多智能体之间的协调和决策可以形式化为分布式部分可观测马尔可夫决策过程（Dec-POMDP）。Dec-POMDP 可以定义为七元组 $\langle S,A,O,R,P,n,\gamma \rangle$，其中 S 是状态空间，A 是动作空间，$o_i=O(s;i)$ 是状态 s 下第 i 个智能体的局部观测，$P(s'|s,A)$ 是给定联合动作 $A=(a_1,\cdots,a_n)$ 时从状态 S 转移到 S' 的转移概率。$R(s,A)$ 是所有智能体共享的奖励函数，γ 是折扣因子。在 Dec-POMDP 中，系统的状态是不可观测的，并以概率方式映射到观测值。观测结果取决于系统状态。智能体的目标是学习策略 $\pi_i(a_i|o_i)$，以最大化折扣奖励 $\sum_{t=0}^{\infty}\gamma^t R(s_t,A_t)$。在无人机群的决策中，为每个无人机提供局部观测，以便根据当前情况做出决策。

在无人机群的多智能体强化学习中，为避免单一智能体视角破坏强化学习的平稳性假设，引入了集中式训练-分布式执行（CTDE）框架，如图 1。依据 CTDE 框架，多智能体强化学习算法有集中式价值网络和价值函数分解两类。集中式价值网络通过集中式方式逼近状态动作价值函数，使智能体基于其他成员行为及全局状态学习策略，适用于各种任务类型。而价值函数分解算法则将总体价值函数拆解为个体智能体的价值函数，每个智能体基于自身价值函数学习策略，主要用于合作任务。

多智能体深度确定性策略梯度（MADDPG）算法[17]在深度确定性策略梯度（DDPG）算法[18]的基础上增加了一个集中式 Q 函数，该函数的输入包括所有智能体的观测和动作。DDPG 使用离策略数据和贝尔曼方程同时学习 Q 函数和策略网络，其中 Q 函数估计在给定状态下采取特定动作的累积期望奖励，策略网络则产生最大化 Q 值的动作。

多智能体近端策略优化（MAPPO）算法[19]是多智能体版本的近端策略优化（PPO）算法[20]，属于 CTDE 框架中的集中式价值网络类。为了重复使用采样得到的数据，避免每次参数更新之后的重新采样，PPO 使用一个策略网络采集训练数据，另一个策略网络进行训练，在两个策略网络产生的训练数据的分布差异过大时，对策略系数进行一定程度的裁剪，防止策略梯度的更新速率过快。

1.2　无人机群攻击算法

多智能体强化学习，作为无人机群模型的理论基石，受到各种安全威胁。根据马尔可夫决策过程四元组中可扰动的空间分类，攻击者可以在策略[15, 20-21]、观测[23-25]和奖励函数[26-27]中进行干扰，影响模型的决策。这些攻击方式已被证实能使智能体的策略混乱，导致其无法完成任务，从而威胁到无人机群模型的安全性。

1.2.1　基于策略的攻击

基于策略的攻击通过训练具有对抗策略的智能体来诱导对手做出错误的决策，示例如图 2。Gleave 等人[15]和 Wu 等人[27]在零和博弈的框架下研究了这一问题，并设计了能够导致其他智能体在竞争环境中产生误判的对抗策略智能体。Li 等人[28]进一步将此对抗策略的设置延伸至合作类多智能体强化学习，证明了使用对抗策略的单个智能体同样能够误导集群，令合作智能集群无法完成既定任务。在 MuJoCo[29]环境中，他们证明了这种策略在模拟机器人零和博弈中的存在和有效性。这种攻击基于对手的观测和动作，旨在最大化受害者的动作偏差，并利用受害者的注意力引导其做出次优的决策。

为克服零和博弈假设的限制，Guo 等人[22]重

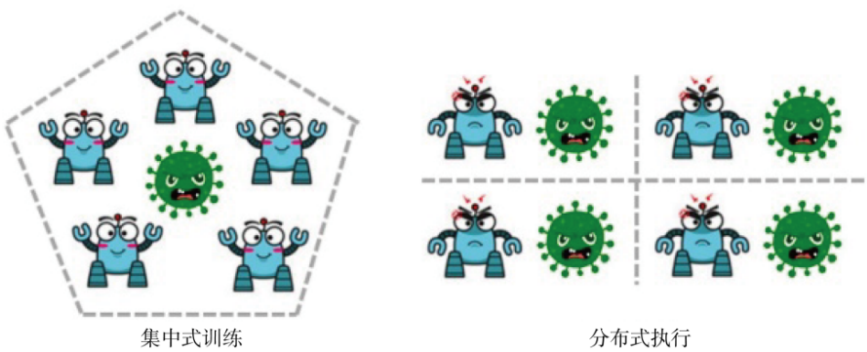


图 1　CTDE 框架示意图

Fig. 1　Schematic Diagram of the CTDE Framework

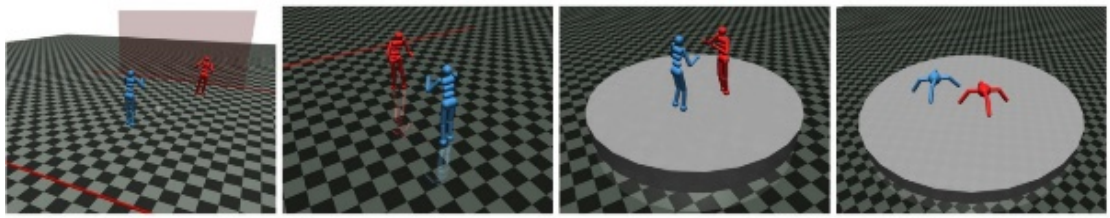


图 2 基于策略的攻击示例[15]

Fig. 2 Example of Policy-Based Attack[15]

塑了一个双人游戏，使攻击者和受害者的预期收益与对抗策略关联。他们设定了对抗策略的学习目标，即最大化攻击者的期望收益和最小化受害者的期望收益，从而在理论上确保策略学习的单调性。这避免了策略更新可能导致的目标随机波动。这种方法对于复杂游戏提供了有效和实际的对抗攻击手段，并首次在星际争霸游戏中实现了成功攻击。

1.2.2 基于观测的攻击

基于观测的攻击通过在智能体观测中注入对抗噪声导致其误判，示例如图 3。Huang 等人[23]采用 FGSM[30]在强化学习输入中添加轻微的噪声，误导了 DQN[31]和 A3C[32]等算法。在 Atari 2600 游戏集[33]的测试中，这些算法对轻微噪声的反应显示出明显的脆弱性。

Lin 等人[34]提出，对每帧的显眼攻击并不理想，强化学习的攻击成功应由最终奖励来评判，而非单步动作的变化。因此，他们提出了两种基于观测的攻击方法：策略化时间攻击和诱导攻击。策略化时间攻击仅在决策关键时刻攻击；而诱导攻击利用预测和规划将智能体引向特定位置。在 Atari 2600 游戏集[33]的实验中，这两种方法都显著降低了智能体的奖励。

Inkawhich 等人[25]为解决对抗攻击对白盒模型的依赖和其它限制，提出了模型窥探攻击方法。如图 4 所示，该方法不要求攻击者与模型的训练环境交互或访问模型的内部参数。攻击者只需监听模型的部分动作或奖励，再训练一个代理模型，使其学习与目标模型相似的任务。因为对抗样本具有迁移性，对代理模型成功的对抗样本也可以成功攻击目标模型。在 Atari 2600 游戏集[33]的实验证明，这种方法具有强大的攻击能力，且与完全知晓目标模型信息的攻击者相当。

1.2.3 基于奖励函数的攻击

基于奖励的攻击目的是扰乱智能体的训练反馈。Behzadan 等人[35]发现强化学习容易遭受模型窃取攻击。他们首先模拟一个目标策略，再初始化一个对抗策略。然后，使用目标策略的奖励变化作为对抗策略的训练奖励。测试结果表明，该对抗策略在 DQN、PPO 和 A2C[32]上都有效且具有可迁移性。

Zhang 等人[36]为强化学习引入了数据投毒攻击，通过向奖励中加入对抗噪声误导智能体。他们提出的自适应攻击方法可以快速投毒，并在机器人路径规划中得到验证。此外，他们对这种攻击方法做了深入的理论分析，确定了噪声的上下界。

1.3 群体智能仿真环境

多智能体强化学习主要集中在三种环境：策略游戏（例如 SMAC、GRF、Hanabi）、粒子环境

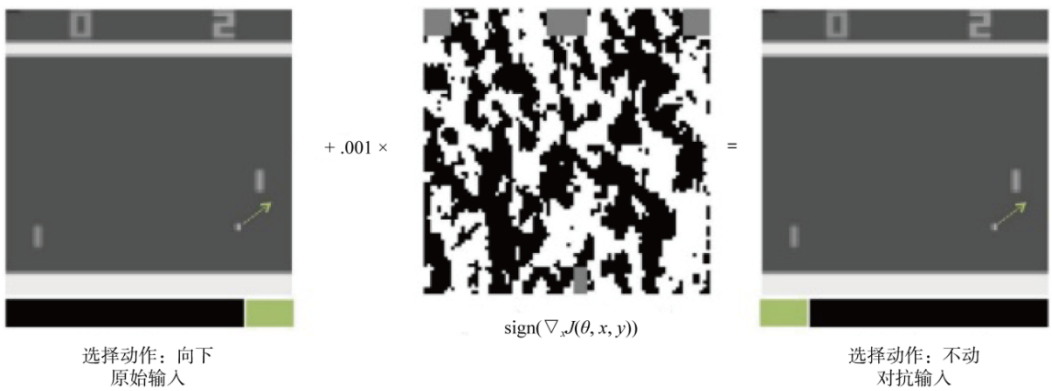


图 3 基于观测的攻击示例[23]

Fig. 3 Example of Observation-Based Attack[23]

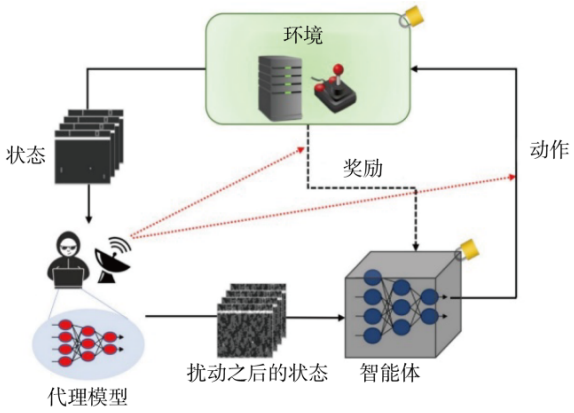


图 4　模型窥探攻击示意图[24]

Fig. 4　Schematic Diagram of Model Peeking Attack[24]

（如 MPE、LBF、RWARE）及机器人环境（如 MAMuJoCo）。大多数策略游戏与粒子环境采用离散动作，而某些粒子及机器人环境则采用连续动作。这些环境的场景任务相对简化，且动作空间的复杂度不高。

SMAC[1]是牛津大学基于 Blizzard 的星际争霸 II 机器学习 API 与 DeepMind 的 PySC2 开发的多智能体离散动作环境，旨在评估合作型多智能体强化学习效果。如图 5，每智能体控制一个游戏单元，执行离散动作，如移动或攻击，但不可同时进行。

MuJoCo[29]是 OpenAI 开发的连续动作机器人学习环境。MAMuJoCo[2]由牛津大学基于 MuJoCo 开发，将原机器人拆分为多智能体，每智能体控制部分机器人，以学习协同移动策略，如图 6 所示。

多粒子环境（MPE）[17]，如图 7，是 OpenAI 公司和加州大学伯克利分校共同开发的一组面向通信的连续动作环境，在这些环境中，粒子智能体可以移动、通信、相互查看、相互推动，并与固定的地标交互。

上述环境虽然能够在一定程度上验证多智能体强化学习的能力，但其任务难以反映真实应用的需要，不具有实际意义。本文提出的无人机群博弈演练环境一方面基于 Airsim 仿真环境提供的高保真动力学模拟方式，能够对于现实环境进行高保真模拟，具有更强的现实意义。另一方面，本文研究的无人机群对战场景与 MPE 等简单环境相比，其场景更为真实，能够较好地满足实际无人机群对战任务的需要，具有更强的应用价值。

2　基于 AirSim 仿真环境的无人机群多智能体对抗平台

据调研，目前不存在一个支持无人机群博弈演练的多智能体强化学习环境，而且现有的群体智能仿真环境在任务的复杂度上远不足以模拟无人机群的博弈行为。针对这一问题，本文拟从设计无人机群对抗环境的角度出发，对无人机群模型可能遭受的各种攻击方式进行统一部署和分析，帮助研究者更好地理解无人机群模型的脆弱性内在机理，促进鲁棒的无人机群训练算法设计。

2.1　无人机群对抗环境设计

设计一个多智能体强化学习环境主要包括：任务场景、单元建模和初始化、观测空间、状态空



图 5　SMAC 环境示例[1]

Fig. 5　Example of the SMAC Environment[1]

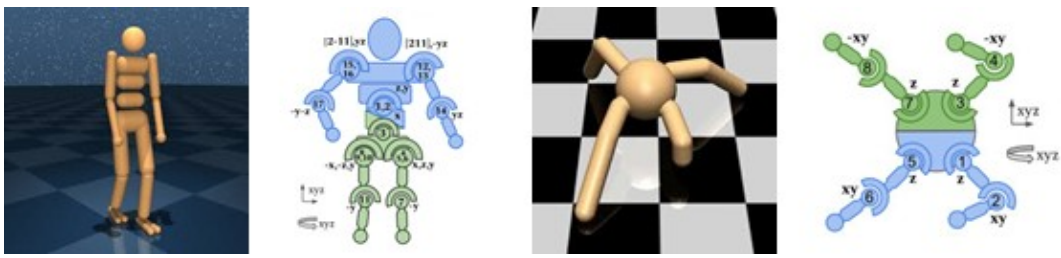


图 6　MAMuJoCo 环境示例[2]

Fig. 6　Example of the MAMuJoCo Environment[2]

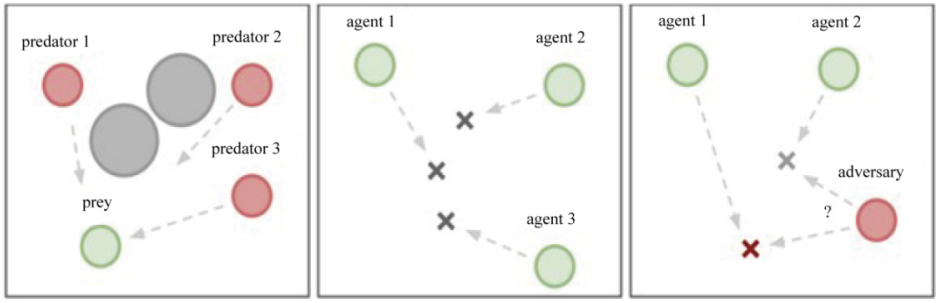


图 7 MPE 环境示例[17]

Fig. 7 Example of the MPE Environment[17]

间、动作空间和奖励函数等概念的设计。此外，为了使得环境对外提供统一的接口，本文遵从 OpenAI 公司的 Gym[32] 接口格式。本文全面分析当前主流的多智能体强化学习算法，并挑选合适的算法适配到无人机群对抗环境中，力求获得一个行为智能的无人机群模型。

2.1.1 无人机群对抗场景的设计

红蓝双方分别有 *n_allies* 架和 *n_enemies* 架在规格上完全相同的无人机在指定大小的空旷空域中进行博弈演练，每一方无人机群的目标是击落攻击者无人机群，赢得对局的胜利。为了尽可能地保证无人机群聚焦于博弈本身，本文限制所有无人机的飞行为二维平面运动。考虑到博弈场景需要的移动策略和无人机群的碰撞避免之间存在一定的矛盾，本文设定每个无人机的高度各不相同，从而避免无人机之间的相互碰撞干扰博弈需要的集群行为，而且该假定并不会影响无人机群仿真的真实性。

如图 8，每个无人机具有 *unit_sight_range* 个单位的观测范围和 *unit_shoot_range* 个单位的攻击范围，只有在观测范围之内的其他无人机（包括受害者和攻击者）才可以被无人机观测。同样地，只有在攻击范围之内的攻击者无人机才可以被无人机攻击。每个无人机可以承受 *unit_health* 次攻击者无人机的攻击，每个无人机至多可以连续攻击 *capacity* 次。当无人机进行了 *capacity* 次攻击之后，需要 *cooldown* 个单位的冷却时间进行调整，其间不可以攻击攻击者。在一个时间单位中，每个无人机最多可以移动 *max_stride* 个单位距离，其方向可以任意，但是无人机不能超出指定的 *map_x* 单位**map_y* 单位的演练场，只要越界，则无人机立即坠毁。

初始化时，每个无人机具有满健康值，按照高斯分布随机在地图中出生，初始速度为 0。见公式（1），为了尽可能地最大化环境的随机性，本文在初始点的左右方向、高斯分布均值和方差中均引入了随机性，再结合高斯分布采样的随机性，确保训

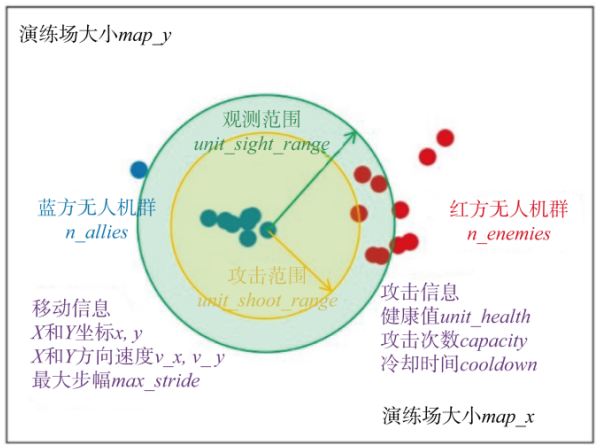


图 8 无人机群对抗场景示意图

Fig. 8 Schematic Diagram of Drone Swarm Confrontation Scenario

练得到的无人机群模型不会受限于某一种或几种初始时的位置分布。

$$\begin{aligned} &Gaussian(x)=\frac{1}{\sqrt{2\pi}\sigma}\exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right),\\ &where\,\mu\sim Random(X_L,Y_L),(X_R,Y_R)+\\ &Uniform(-2,2),\sigma\sim Uniform(1,4) \end{aligned} \tag{1}$$

其中，X_L 和Y_L 是无人机群的左侧中心出生点，X_R 和Y_R 是无人机群的右侧中心出生点。在每一个时间单位中，环境接受外部输入的动作，用于指示当前时间单位中无人机群的动作，同时执行每个无人机的攻击和移动动作。在当前时间单位的动作完成之后，检查每个无人机的位置并清除越界的无人机，再统计双方无人机的存活情况和健康值变化情况，决定对局是否结束并计算当前时间步的奖励函数。为了减少对局的后期可能出现的大量无效动作，当对局进行到第 *episode_limit* 步时，无论是否胜利，当前局均结束。

2.1.2 观测空间和状态空间设计

本文设计的无人机群对抗环境遵循集中式训练-

分布式执行的框架逻辑，每个无人机的观测空间只包括该无人机周围的局部环境信息，用于分布式执行；环境的全局信息只存在于无人机的状态空间，用于集中式训练。如图 9，每个无人机的观测空间由四部分组成：移动特征、攻击者特征、受害者特征和自身特征。

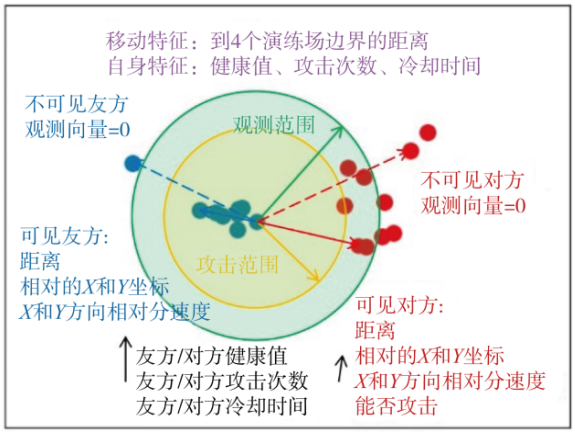


图 9　无人机群观测空间示意图

Fig. 9　Schematic Diagram of the Drone Swarm Observation Space

首先，移动特征允许无人机感知到演练场的四个边界，使其明确边界限制，从而避免超出范围。接着，对于敌方无人机，无人机仅能感知到其范围内且仍存活的单位。这其中包括了敌机的位置信息、相对速度以及其是否处于可攻击范围内。而根据任务的复杂性，我们还考虑了一些可选的特征，例如敌机的健康值、剩余攻击量和冷却时间。值得注意的是，对于不在观测范围或已坠毁的敌机，其相关特征都被设置为 0。

同样地，受害者无人机的观测也是不可或缺的，它们也仅限于在观测范围内且仍存活的单位。除了基本的位置和速度信息外，根据不同的无人机型，我们还提供了可选的健康值、剩余攻击次数和冷却时间特征。同样地，对于不在范围或已坠毁的友机，其特征也被置为 0。最后，考虑到自身决策的需求，无人机还能感知到自身的健康状态、剩余的攻击次数和冷却时间，同时，为了在共享网络中准确地区分不同无人机，每个无人机还配备有一个表示其 ID 的独热向量。

本文通过引入"obs_instead_of_state"参数，实现了两种状态空间：1）将同一阵营无人机群中各个无人机的观测空间连接构成整体状态空间；2）考虑每个存活单位的状态，包括无人机的健康、相对演练场中心的坐标以及 X、Y 方向的绝对分速度、剩余攻击次数、冷却时间，坠毁无人机状态为 0。此外，通过"state_last_action"参数，选择是否融入上个时间步的动作。状态空间中的独热向量用于区分无人机身份。

2.1.3　动作空间和奖励函数设计

与主流纯离散或纯连续动作空间不同，本环境采用混合动作空间，允许无人机同时攻击和移动。图 10 展示了动作空间设计。攻击动作为离散动作，0 表示不攻击，其它数值代表攻击对应编号的敌机。攻击是指向性且必中。移动动作为连续动作，使用 X 和 Y 方向分速度控制飞行。

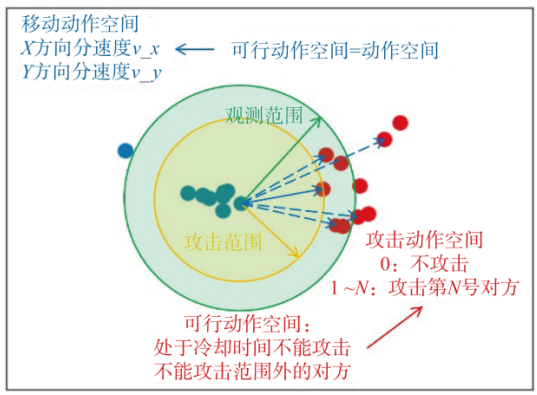


图 10　无人机群动作空间示意图

Fig. 10　Schematic Diagram of the Drone Swarm Action Space

如图 10，引入可行动作空间限制无人机动作，防止非法行为（如超出攻击范围、攻击已坠毁敌机、冷却时攻击）。对移动动作，未限制越界，默认速度为 1。对攻击动作，第 0 维为 1 表示不攻击，以期待更大长期奖励；其它维度为 1 仅在敌机在攻击范围且存活，且无人机有攻击次数。攻击时，速度减慢（*slowdown* 倍），模拟攻击调整。已坠毁无人机不执行动作，动作空间失效。

本文支持通过"reward_sparse"参数使用稀疏或稠密奖励函数。胜利定义为：时间内受害者存活、攻击者全坠毁；战败定义为：时间内攻击者存活、受害者全坠毁；平局定义为：某时间内受害者和攻击者全坠毁。未在时间内结束的对局不定义结果。

对于稀疏奖励函数，只在胜利奖励为 1，失败奖励为－1，其他时刻奖励为 0。

对于密集奖励函数，如图 11 所示，可进一步设定"reward_only_positive"参数，以区分仅包含正奖励项的单方奖励函数或同时包括负奖励项的双方奖励函数。

单方奖励函数：当前时间步奖励为新坠毁攻击

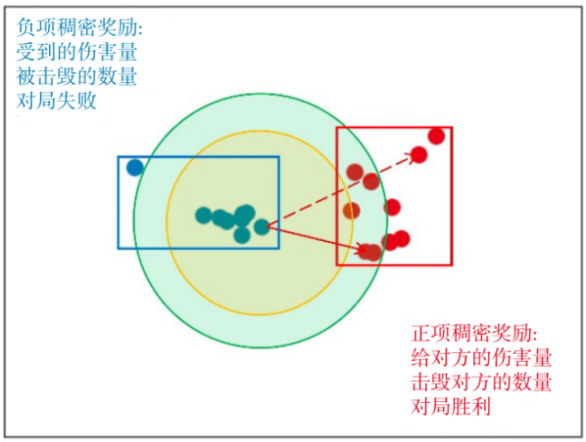


图 11 无人机群奖励函数示意图

Fig. 11 Schematic Diagram of the Drone Swarm Reward Function

者无人机数量 * "reward_death_value" + 造成攻击者无人机伤害量。若当前时间步获胜，再加上"reward_win"。

双方奖励函数：在单方奖励函数基础上，对称地增加三项：新坠毁受害者无人机数量 * "reward_death_value" * "reward_negative_scale"，受害者无人机受伤害量 * "reward_negative_scale"。若当前时间步失败，再加上"reward_defeat"。

为促进无人机群协作，同一方所有无人机共享相同奖励函数。此外，为限制奖励函数值范围，支持"reward_scale"和"reward_scale_rate"参数进行缩放。需要说明的是，对于越界行为，不直接设定相关奖励函数，而通过强制坠毁越界无人机的方式，间接引导无人机群模型认知边界限制，从而学习不移出边界的规则。

2.1.4 无人机群模型的训练策略

本文中，无人机群的动作空间设计对多智能体强化学习算法的选择起决定性作用。经研究，QMIX 算法[35]只适用于离散动作空间；MADDPG 算法[18]虽能通过重参数化技巧拓展，但其效果和效率不佳；而 MAPPO 算法[19]在离散和连续动作空间都表现出色。因此，本文采用 MAPPO 算法进行无人机群训练，训练策略如图 12。

虽然无人机群采用混合动作空间，但其结构与四种常见的混合动作空间（参数化动作空间、多维离散动作空间、多元二进制动作空间和层次结构的动作空间）大相径庭。直接应用 MAPPO 算法未能获得满意结果，因为移动和攻击策略网络共享奖励函数，导致无法准确分配奖励，例如无法在冷却时间内学习躲避攻击。为解决此问题，本文基于强化学习中的动作分支架构[37]提出了两种方案，实现两个动作空间的有机融合。

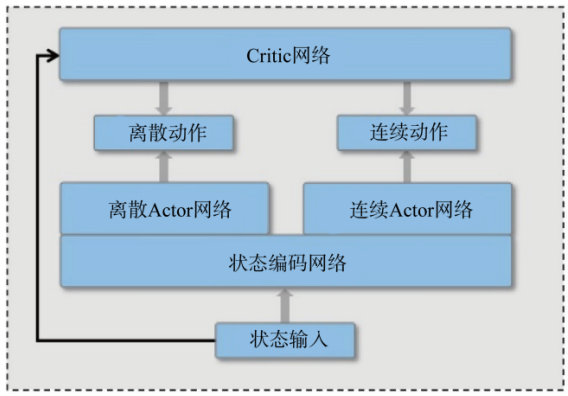


图 12 无人机群的训练策略示意图

Fig. 12 Schematic Diagram of the Training Strategy for Drone Swarms

方案 A：共享两策略网络的底层特征提取，顶层网络分别输出离散动作和连续动作的参数。方案 B：结合方案 A，考虑攻击动作的指导性，将攻击动作输出与观测特征一同输入到移动策略网络，增强决策信息。

为促进无人机间信息流通，所有同一阵营的无人机共享攻击和移动网络参数，实现隐式通信并优化策略。本研究支持：（1）Self-play 训练。无人机群环境支持双方视角切换，并开启对手模型采样，确保模型持续进化并能应对不同对手。（2）由于使用 self-play 训练的智能体未能涌现出较为复杂的技巧，我们增添了一方使用手工设计的战斗规则（修改前称为“基于规则的训练”，已修改为“一方使用手工设计的战斗规则”），一方使用多智能体强化学习的训练范式。具体而言，手工设计的战斗规则支持无人机优先攻击最近距离目标，不在攻击范围内则优先靠近最近距离目标，冷却时则远离。在实际应用中，智能体在与基于规则的智能体训练的过程中，学习到了更好的战斗技巧与策略。

2.2 无人机群对抗攻击体系研究

基于 2.1 节设计的无人机群对抗环境和使用多智能体强化学习算法训练得到的无人机群模型，本研究提出无人机群对抗攻击体系，从基于策略的攻击、基于观测的攻击、基于奖励函数的攻击、基于少数群体的攻击和基于多数群体的攻击五个方面对于无人机群鲁棒性体系化研究与评测，代码结构如图 13。

2.2.1 基于策略的对抗攻击算法

基于策略的攻击指在无人机对抗场景中，受害

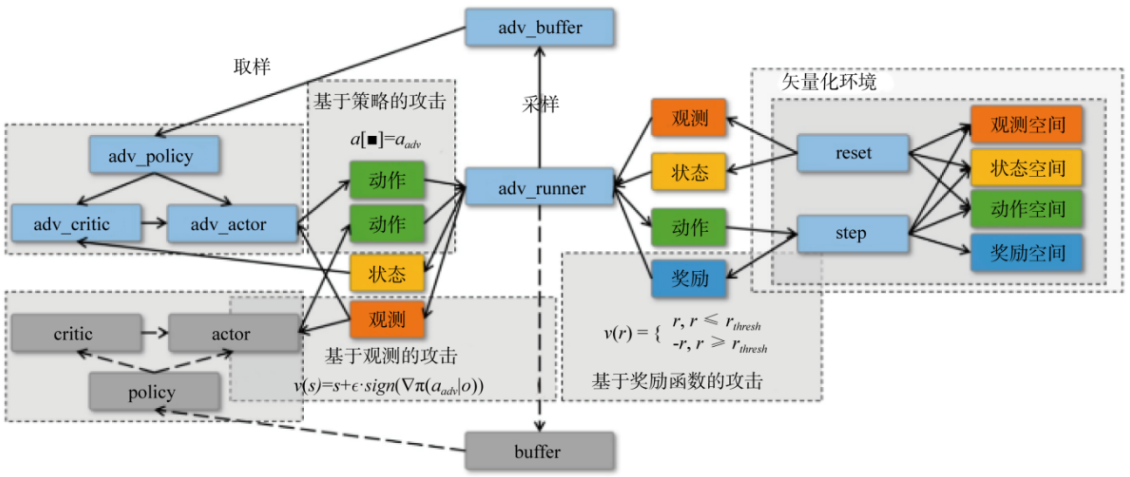


图 13　无人机群对抗攻击算法的代码结构

Fig. 13　Code Structure of Drone Swarm Counterattack Algorithm

者无人机群中引入“内鬼”作为被攻击对象，通过其异常动作干扰其他受害者无人机的正常行为。此攻击方法在被攻击模型的测试阶段进行黑盒攻击，其中攻击过程包含对抗性策略的训练。基于策略的攻击通过替换多智能体环境中某个智能体的策略来实现，无需改变环境或奖励函数。在应用场景中，无人机群内可能包含从多个厂家采购的无人机，其中部分厂家提供的无人机具有安全风险，如后门等，从而被攻击者劫持并操控。

设对抗性策略智能体和遭受攻击的正常智能体策略为π@和πA。对抗性策略训练期间，固定πA，对抗性智能体将遭受攻击智能体视为环境的一部分。同时设计奖励函数，以正常智能体性能下降为目标，为对抗性策略智能体提供相应奖励。该目标优化可用公式（2）表示：

$$max\sum_{t=0}^{\infty}\gamma^t R_{adv}\left(s_t,a_t^a,s_{t+1}\right),a_t^a\sim\pi_a\left(\cdot|s_t\right). \tag{2}$$

其中，R（BC 为对抗策略智能体的奖励函数，根据特定的对抗目标给予奖励。基于策略的对抗样本生成使用强化学习方法训练对抗策略，针对特定的目标策略生成对抗策略，具有针对性的攻击效果。

基于策略的攻击利用单/多智能体强化学习，训练“内鬼”无人机，目标是影响对局结果。一般对抗策略[14]仅用于双人博弈。本文通过替换无人机策略为对抗策略，将其视为“内鬼”，在对抗训练中将其视为单一智能体任务。设对抗策略的奖励为r'，则基于策略的攻击可以形式化为公式（3）：

$$\nu\left(\pi\right)=\pi_\alpha\left(s\right),\text{s.t.}\underset{\nu(\pi)}{max}\sum_{k=0}^{\infty}\gamma^k r'_{t+k}. \tag{3}$$

由于无人机群动作空间由两个结构上相互独立、逻辑上相互耦合的攻击动作子空间和移动动作子空间构成，直接将针对单智能体 PPO 的攻击迁移到 MAPPO 会存在类似 2.1.4 节中的问题，“内鬼”无人机的攻击策略网络和移动策略网络相互混淆，互不相关。本文结合 2.1.4 节的策略 A 或策略 B，适当调整对抗策略。

2.2.2　基于观测的对抗攻击算法

基于观测的攻击通过扰动无人机群的观测空间使得无人机群做出错误的动作，从而对最终的奖励产生负面影响。基于观测的攻击可用公式（4）表示：

$$\begin{aligned}&\underset{\nu(s)}{min}G_t=\sum_{k=0}^{\infty}\gamma^k r_{t+k},\\&\text{s.t.}\nu\left(s\right)\in B\left(s\right),s'\sim\\&P\left(s'|s,\left\{a^i\right\}\right),\left\{a^i\right\}\sim\pi\left(\cdot|\nu\left(s\right)\right).\end{aligned} \tag{4}$$

模型测试阶段的攻击仅用观测数据。由于训练时多智能体强化学习算法遵循 CTDE 框架，接受全局状态输入，测试时仅接受各智能体局部观测，故采用基于梯度攻击（如快速梯度符号法（FGSM）[30]、投影梯度下降法（PGD）[38]）。在测试中，向一个/多个无人机的局部观测添加对抗噪声。

基于梯度攻击通过计算输入梯度相对于损失函数的方向，用梯度上升等方式添加对抗性扰动。FGSM 根据梯度符号一次性扰动输入，效率高但攻击弱。PGD 在 FGSM 基础上迭代，微扰动限制在范围内，累积多次以获得对抗样本。PGD 比 FGSM 攻击力强，可在适当计算时间内生成接近最优一阶对抗样本。本文采用 PGD 攻击基于观测。

当前多智能体强化学习中，观测空间攻击集中于 QMIX[10]，目标是减小目标智能体 Q_{total} 值。然而，

MAPPO 无用于动作评估的网络，确定强攻击目标较难。故选取“内鬼”无人机动作为攻击目标，通过扰动观测，使目标无人机模仿“内鬼”动作。

具体而言，定义$a* = \arg max\ \pi'(a|o)$为 2.2.1 节得到的“内鬼”无人机策略输出的最优攻击动作，$\pi(a*|o)$为被攻击的无人机在观测 o 下选择动作 a* 的概率，则基于观测的攻击可以表示为公式（5），其中 sign（·）是符号函数，ε约束添加的噪声大小：

$$v(s)=s+\epsilon\cdot\mathrm{sign}\left(\nabla\pi_o\left(a^*|o\right)\right). \tag{5}$$

2.2.3 基于奖励函数的对抗攻击算法

基于奖励函数的攻击旨在干扰无人机群的内部信息，从而扰动无人机群的行为。在实际应用中，奖励函数可能由于传感器错误，软件故障导致奖励函数错误，从而使得算法在获得较高错误奖励函数的同时，无法优化真实的奖励函数[39]。不同于 2.2.1 节和 2.2.2 节中在模型的测试阶段进行的攻击，基于奖励函数的攻击是在模型的训练阶段进行的攻击。基于奖励函数的攻击是黑盒攻击，无需知晓任何模型结构信息，仅需掌握对一定的奖励函数控制权，通过扰动环境反馈给无人机群的奖励信号，使得无人机群在训练过程中接收到错误的奖励信息，从而使得策略表现较差。基于奖励函数的攻击可以形式化为公式（6）：

$$\begin{aligned}&\min_{v(r)}G_t=\sum_{k=0}^{\infty}\gamma^k r_{t+k},s.t.v(r)\in B(r),s'\sim\\&P\left(s'|s,\{a^i\}\right),\{a^i\}\sim\pi\left(\cdot|s,v(r)\right).\end{aligned} \tag{6}$$

在本文设计的无人机群对抗环境中，同一阵营的所有无人机共享奖励函数，因此，只需要干扰共享的奖励函数就可以完成攻击。借鉴计算机视觉社区的数据“投毒”，在本文中，我们定义基于奖励函数的攻击为，在一局中所有时间点下，将值最大的 $k\%$（本文中设置为 5%）奖励进行符号翻转。这种攻击可以被看作奖励函数不准确的一种[40-41]。假设值最大的 $k\%$奖励阈值为 r_{thresh}，则基于奖励函数的攻击可以表示为公式（7）：

$$v(r)=\begin{cases}r, r\le r_{\text{thresh}}\\-r, r>r_{\text{thresh}}\end{cases} \tag{7}$$

2.2.4 基于少数群体的对抗攻击算法

基于少数群体的攻击旨在针对性地强化攻击者无人机群中的少数无人机，从而小幅度地降低被攻击的受害者无人机群的行为智能程度。如表 1，不同于上述三种攻击方式需要直接扰动一个或多个受害者无人机的策略、状态或奖励函数，基于少数群体的攻击只需要使用 MAPPO 算法“正常”训练攻击者无人机群中的少数群体，与受害者无人机群进行竞争性交互，是一种测试时的黑盒攻击。

值得注意的是，在此场景中，由于两方智能体的目标不同，此问题被定义为一个部分观测随机博弈（Team POSG，partially observable stochastic game）。POSG 可以定义为七元组$\langle N,S,A,O,R,P,\gamma\rangle$，其中 $N=\{N^\alpha,N^\beta\}$是两组智能体，S 是状态空间，A 是动作空间，$o_i=O(s;i)$是状态 s 下第 i 个智能体的局部观测，$P(s'|s,A)$是给定联合动作 $A=(a_1,\cdots,a_n)$ 时从状态 S 转移到 S' 的转移概率。$r^i=R(s,A,i)$是智能体的奖励函数，且 $\forall i\in N^\alpha$, $r^i=r^\alpha$，$\forall j\in N^\beta$, $r^j=r^\beta, r^\alpha=-r^\beta$，$\gamma$ 是折扣因子。在 POSG 中，系统的状态是不可观测的，并以概率方式映射到观测值。观测结果取决于系统状态。每个智能体的目标是学习策略 $\pi_i(a_i|o_i)$，以最大化自身获得的折扣奖励 $\sum_{t=0}^{\infty}\gamma^t R(s_t,A_t,i)$。在无人机群的决策中，为每个无人机提供局部观测，以便根据当前情况做出决策。

表 1 无人机群攻击算法

Table 1 Drone Swarm Attack Algorithms

攻击算法	攻击时机	攻击信息	攻击者阵营	攻击数量/个
基于策略的攻击	测试阶段	黑盒攻击	受害者	1
基于状态的攻击	测试阶段	白盒攻击	受害者	1
基于奖励函数的攻击	训练阶段	黑盒攻击	受害者	N
基于少数群体的攻击	测试阶段	黑盒攻击	攻击者	$N/3$
基于多数群体的攻击	测试阶段	黑盒攻击	攻击者	N

2.2.5 基于多数群体的对抗攻击算法

基于多数群体的攻击旨在针对性地强化攻击者无人机群中的多数无人机，从而大幅度地降低被攻击的受害者无人机群的行为智能程度。如表 1 所示，类似于基于少数群体的攻击算法，基于多数群体的攻击不需要直接扰动受害者无人机群的任何信息，只需要使用 MAPPO 算法“正常”训练攻击者无人机群中的多数群体，与受害者无人机群进行竞争性交互，同样是一种测试时的黑盒攻击。

3 实验结果与分析验证

本章详述实验部分，主要分析无人机群模型的行为及其攻击算法。所有实验均在先前介绍的无人机群对抗平台上进行。鉴于强化学习算法的效果深受代码技巧和超参数配置的影响，并且在不同环境

中需要专门的配置，每个实验小节都会明确列出算法和环境参数，以确保实验的可复现性。

在可视化方面（如自定义视图、无人机模型等），如图 14 所示，本文在 Windows 系统上，基于虚幻引擎 UE4.27 构建新地图，将编译的 AirSim-v1.7.0 作为插件添加至引擎工程。Python 程序调用 AirSim 的 Multirotor API 控制无人机移动、获取状态等。

3.1　无人机群模型的行为分析

在训练无人机群模型时，基于 Self-play 的模型表现不佳，因此选择了基于规则的训练。由于策略 A 和策略 B 表现相似，我们采用简单的策略 A 进行训练。详细的超参数配置见表 2，且 MAPPO 的超参数参照文献[18]。在本文中，我们首先在无攻击场景下训练多智能体强化学习算法，随后固定此算法参数，对其进行对抗攻击，以模拟算法部署期间的不确定性影响。训练的胜率与奖励曲线如图 14 所示，基于多智能体强化学习算法在经过训练后，由强化学习算法控制的无人机群在与基于规则的智能体进行交互时，通过试错不断更新自己的策略，从而以较高的胜率战胜基于规则的无人机群算法，显示出了多智能体强化学习策略的优越性。

图 15 展示了无人机群模型的典型行为，主要包括 4 种：集群、集火、退避和追击。

1）集群行为：初始化后，同一阵营的无人机迅速集结前往攻击者进行博弈，而不是独立行动。

2）集火行为：无人机群会有针对性地攻击攻击者某个无人机，逐一击败，而不是分散火力。

3）退避行为：无人机在冷却时会快速远离敌方，保存自身，而不是贸然前行。

4）追击行为：攻击者撤退时，无人机会及时追击，而不是迟疑不决。

3.2　无人集群攻击算法分析

本文设计的对抗环境和训练算法增强了随机性，确保基于规则训练的单方无人机群模型可以适应双方应用。在攻击实验中，双方使用相同的无人机群模型进行对抗，同时替换部分无人机的模型以进行攻击。考虑到攻击时的对手模型与手工规则不同，我们调整了一些环境参数：无人机的视觉范围（unit_sight_range）减小到 9，为了提高对局的持续时间和行为多样性，无人机的健康值（unit_health）增加到 15。其它环境参数保持不变。

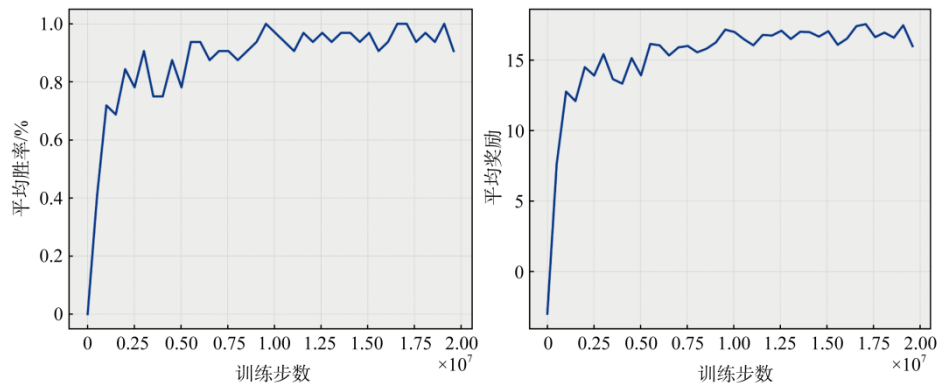


图 14　无人机群模型的训练结果

Fig. 14　Drone Swarm Model Training Results

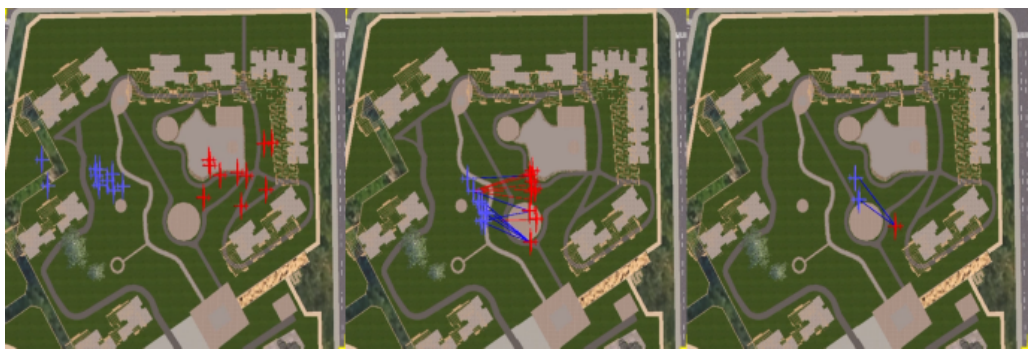


图 15　正常无人机群模型的演示

Fig. 15　Demonstration of Normal Drone Swarm Model

表 2 无人机群攻击算法的分析

Table 2 Analysis of Drone Swarm Attack Algorithms

参数	配置	参数	配置
lr	10	n_enemies	10
fire_actor_lr	=lr	move_actor_lr	=0.1*lr
batch_size	100	buffer_size	100
timesteps	2e8	use_rnn	False
hidden_dim	64	n_layer	1

3.2.1 基于策略的对抗攻击算法

在策略攻击中，一个受害者无人机作为“内鬼”。训练中，reward_only_positive 设为 False，其他参数不变。“内鬼”的奖励与被攻击无人机相反。期间，被攻击的受害者及所有敌方无人机策略被冻结。此训练与单智能体的 PPO 相似。详细胜率和奖励曲线见图 16，其中，红色虚线表示无攻击下的胜率，蓝色实线表示存在攻击时的胜率。此外，与 $t=0$ 时刻未经训练，从而做出随机动作的“内鬼”相比，使用强化学习训练的“内鬼”可以将无人机群获得的总奖励函数从−4.83 降低至−11.75，从而取得更为针对性的破坏效果。值得注意的是，在“内鬼”攻击中，由于环境限制，攻击者无法直接对于自己的队友进行攻击，而是通过当前时间段做出具有对抗性的动作，从而扰乱队友在下一个时间段的观测，从而令队友做出非最优的动作，进而达成攻击效果。

如图 17 所示，在测试中，“内鬼”无人机在初始化阶段避免集结，而是立即超出边界，导致自己坠毁，留下其他受害者无人机与敌方博弈。只要“内鬼”位于敌方攻击范围内，它都可能分散敌方火力，为受害者提供某种保护。其最佳策略是从开始就离开战场，以最小化对受害者的干扰。

3.2.2 基于观测的对抗攻击算法

利用“内鬼”模型的策略，我们指导基于观测的攻击。如预期，被攻击的无人机的行为与“内鬼”相似。利用 PGD 攻击算法，如图 18 所示，当扰动覆盖整个观测空间时，基于观测的攻击效果与基于策略的攻击相当。但是，当观测扰动范围较小时，添加在输入上的噪声无法任意对网络输出进行

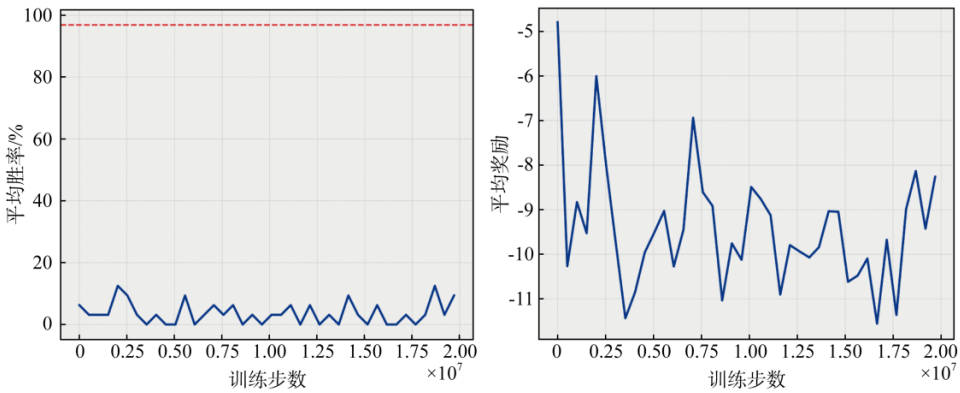


图 16 基于策略的攻击结果

Fig. 16 Policy-Based Attack Results

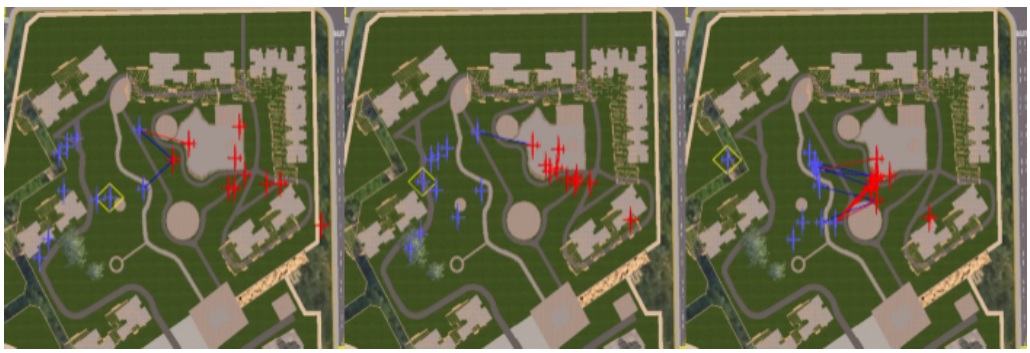


图 17 基于策略的攻击演示

Fig. 17 Policy-Based Attack Demonstration

扰动，从而无法将被攻击者的策略误导至足够有攻击性的动作，进而无法取得与基于策略的攻击相当的攻击效果。

表 3 展示了基于观测的攻击效果，作为基于策略攻击的上界，效果稍微逊色，这与预期相符。随着扰动范围的限制，攻击效果逐渐减弱，扰动范围为 0 时，攻击效果消失。

表 3　基于观测的攻击结果

Table 3　Observation-Based Attack Results

扰动大小 限制 $\ell\infty$	单步扰动 幅度	迭代步数	胜率	奖励
基于策略的攻击	—	—	0.031 2	-9.147 2
1	0.1	5	0.062 5	-8.879 2
0.75	0.1	5	0.093 8	-8.161 1
0.5	0.1	5	0.156 2	-7.875 0
0.25	0.1	5	0.125 0	-7.552 8
0	0.1	5	0.406 2	-1.187 5

3.2.3　基于奖励函数的对抗攻击算法

基于奖励函数的攻击在训练时配置 reward_only_positive 参数为 False。与基于策略和观测的攻击不同，此攻击是训练中实现的。按照 3.1 节的流程再次进行训练，仅修改奖励信号，将每局最大的 5% 奖励的符号反转，其它训练配置与多智能体的 MAPPO 相同。训练的胜率和奖励曲线如图 19 中所示。其中，红色虚线表示无攻击下的胜率，蓝色实线表示存在攻击时的胜率。通过仅修改 5%奖励函数，攻击者即可轻易使无人机群无法学到有效的策略，体现了使用多智能体强化学习控制的无人机群在训练时的脆弱性。由于部分时段下关键的奖励函数被翻转，多智能体强化学习算法基于错误的奖励函数进行学习，从而无法正确奖励能够获得更高奖励函数，导致算法学习到次优策略。

在奖励函数攻击下，我们获得了一个表现较差的无人机群模型。如图 20 所示，所有无人机直接超越演练场边界，实施集体“自杀”，而没有与敌方无人机交战。这些被攻击的无人机行为与基于策略攻击的“内鬼”无人机相似。

3.2.4　基于少数群体的对抗攻击算法

在少数群体攻击下，我们重新训练了攻击者无

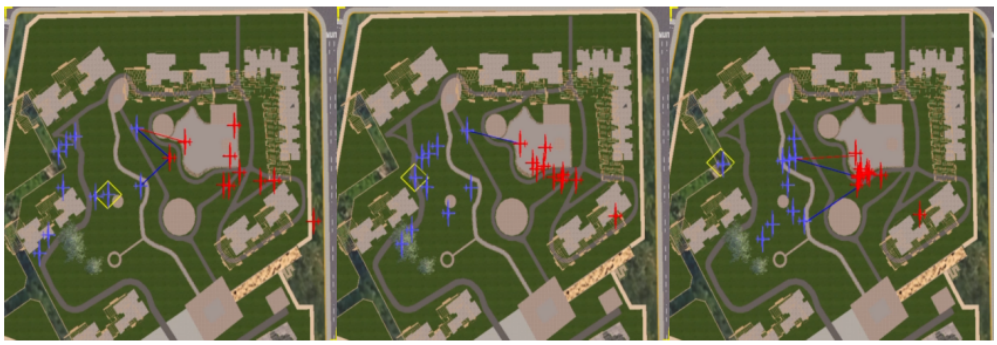


图 18　基于观测的攻击演示

Fig. 18　Observation-Based Attack Demonstration

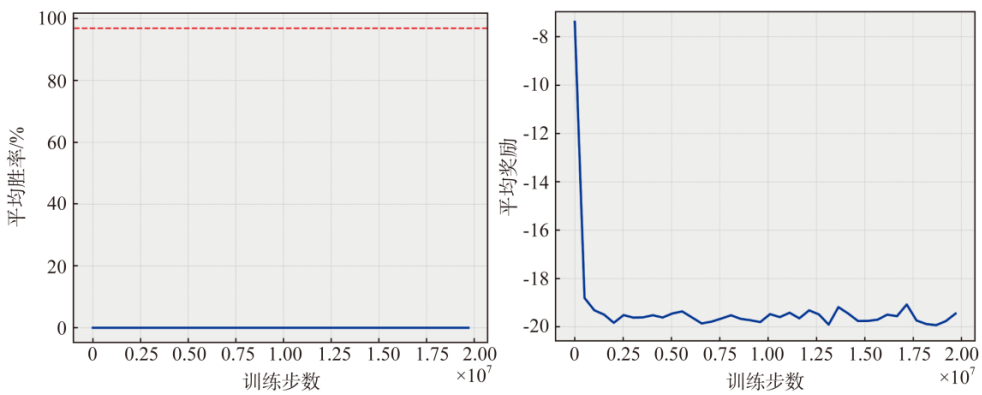


图 19　基于奖励函数的攻击结果

Fig. 19　Reward Function-Based Attack Results

人机群中的 3 架。设定 reward_only_positive 为 True，保持其他参数。在此过程中，仅对这 3 架无人机应用 MAPPO 训练，同时冻结其它无人机。训练的胜率和奖励曲线见图 21。其中，红色虚线为双方均为多智能体强化学习时攻击者的胜率，蓝色实线为基于少数攻击后的胜率。通过使用基于少数群体的对抗攻击算法对于被攻击者无人机群脆弱性进行挖掘，攻击者可以在无人机集群对抗中提高 20% 胜率。与基于策略的对抗攻击相似，基于少数群体的对抗攻击算法通过令当前时刻对手采用与训练时不同的策略，从而影响被攻击者的观测。由于被攻击者的策略鲁棒性不足，当其观测改变时，被攻击者的策略无法对攻击者策略的改变做出灵活的反应，从而无法应对改变策略后的攻击者。

虽然少数群体对战局影响有限，但其胜率存在一定提高，证明之前的无人机模型具有一定的脆弱性。胜率增长主要有两个原因。

情形一：攻击者优势。对局初期，少数群体智能配合，维持与被攻击无人机距离，使其他无人机成为攻击者焦点，导致攻击者无效攻击。同时，这些无人机与同方保持距离，局部集火，减少无效伤害。对局后期，当多数同方无人机坠毁，健康的少数群体集火打击攻击者残余无人机，如图 22 所示。

情形二：攻击者劣势。由于双方实力接近，初始布局或造成初期快速失势。此时，少数群体尽量与攻击者保持距离，保存实力。后期，当大量攻击者无人机寻找少数群体，这些无人机诱导追踪的攻击者趋近场边，然后突然调头，使攻击者因惯性冲出边界并坠毁，如图 23 所示。

3.2.5 基于多数群体的对抗攻击算法

在基于多数群体攻击中，我们重新训练了所有攻击者无人机，配置中仅将 reward_only_positive 设置为 False，其他参数保持不变。训练中，受害者无人机模型被冻结，相当于 3.1 节的正常模型训练，只是换成了 3.1 节得到的规则，训练结果如图 24 所示。其中，红色虚线为双方均为多智能体强化学习时攻击者的胜率，蓝色实线为基于少数攻击后的胜率。通过使用基于多数群体的对抗攻击算法对被攻击者无人机群脆弱性进行挖掘，攻击者可以在无人机集群对抗中提高 35%胜率。在问题设置方面，基于多数群体的对抗攻击算法与基于少数群体的对抗攻击算法较为相似。但是，由于基于多数群

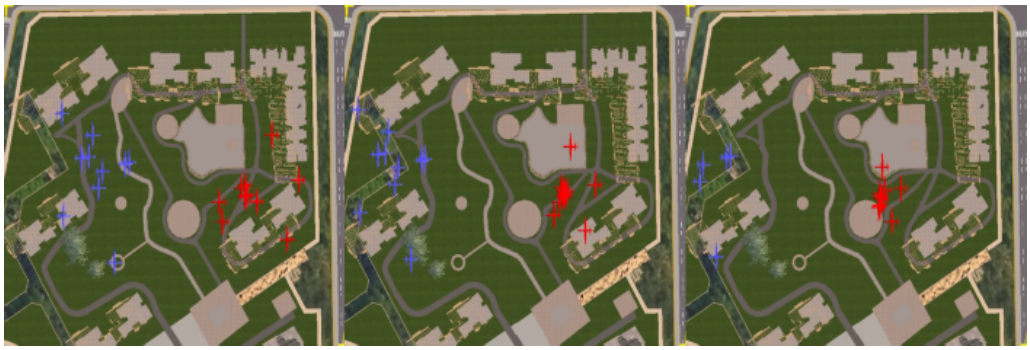


图 20 基于奖励函数的攻击演示

Fig. 20 Reward Function-Based Attack Demonstration

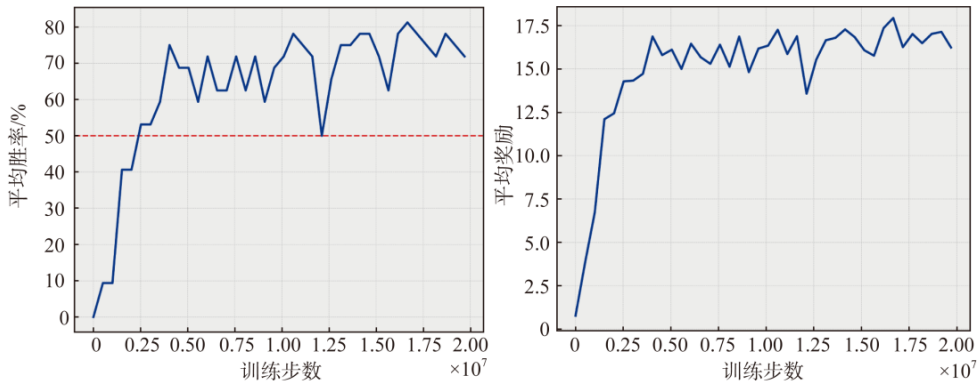


图 21 基于少数群体的攻击结果

Fig. 21 Minority-Based Attack Results

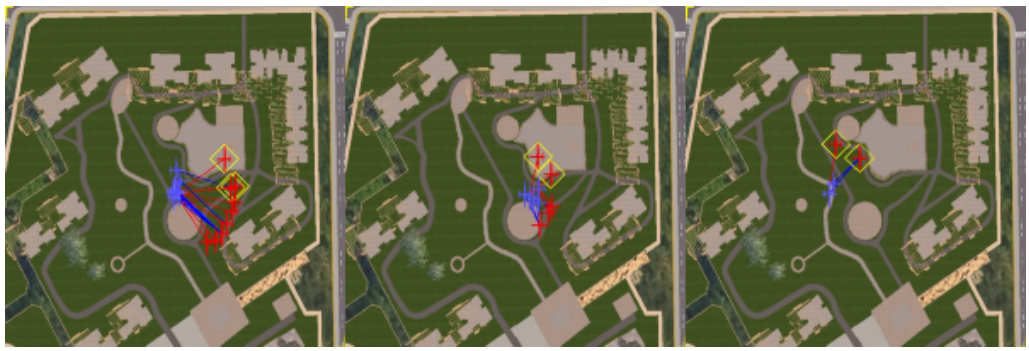


图 22　基于少数群体的攻击演示一

Fig. 22　Minority-Based Attack Demonstration I

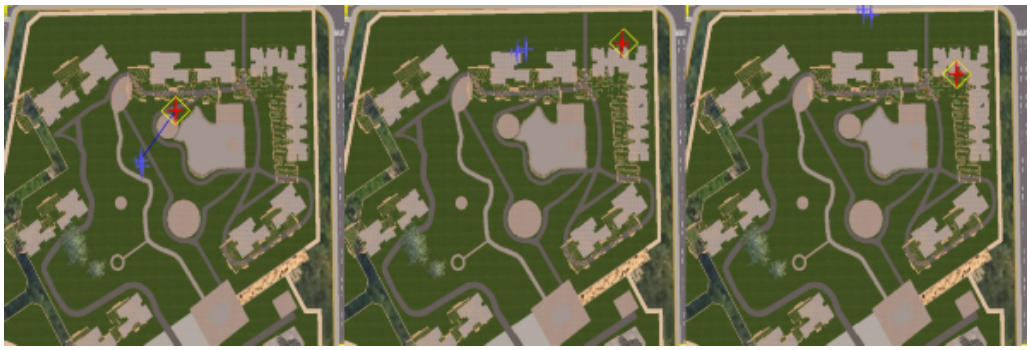


图 23　基于少数群体的攻击演示二

Fig. 23　Minority-Based Attack Demonstration II

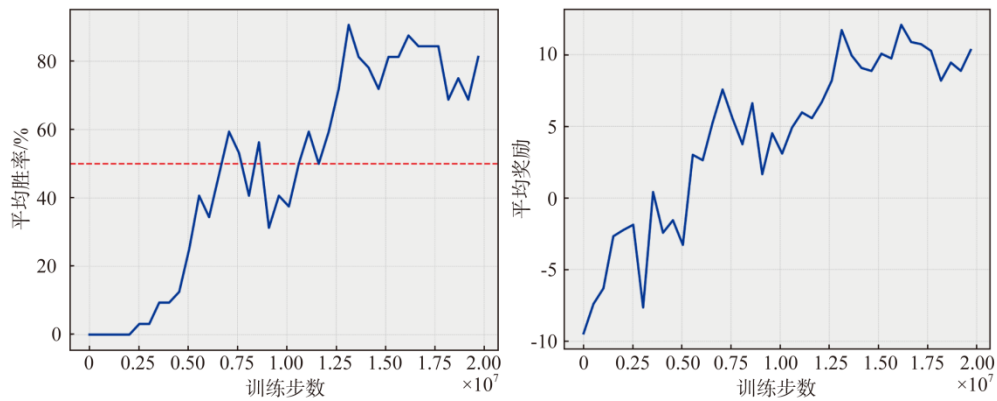


图 24　基于多数群体的攻击结果

Fig. 24　Majority-Based Attack Results

体的对抗攻击算法能够控制更多数量的智能体，因此，攻击者可以通过较大幅度地修改自身策略，从而更好地误导被攻击者。一方面，此现象反映了现有的多智能体强化学习算法学习过程中远未学到全局最优的均衡策略，从而使得攻击者有机可乘。另一方面，由于强化学习算法常使用深度神经网络作为编码器，而深度神经网络本身是非凸非凹函数，这也为在 POSG 中学习全局最优的鲁棒均衡策略带来了极大的挑战。

在多数群体攻击中，攻击者主要瞄准了 3.1 节描述的集群行为，导致被攻击的攻击者无人机群的集群行为发生偏差，并进一步影响其集火行为。如图 25 所示，对局开始时，双方都在集结。但攻击者没有在中轴线上集结，而是稍微偏移，再在被检测

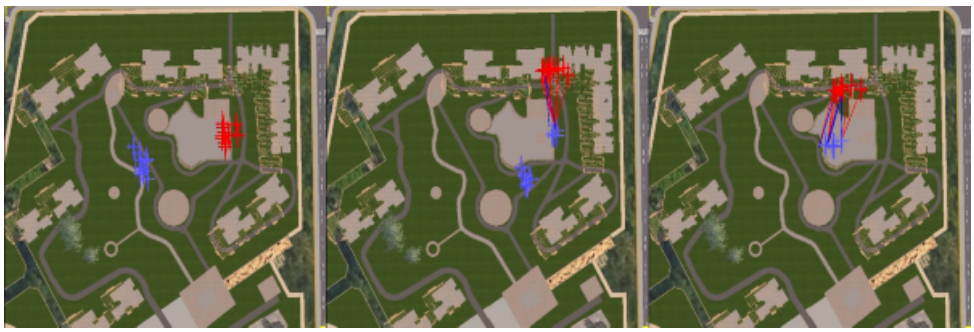


图 25 基于多数群体的攻击演示

Fig. 25 Majority-Based Attack Demonstration

后向远处撤退。这使前锋的攻击者无人机快速追击，而后方的无人机缓慢跟随，导致攻击者队形分散。先进的攻击者无人机首先被多数群体击败，随后的攻击者无人机在到达时也被集火消灭。

3.3 无人机群对抗攻击算法实验验证

本文基于 AirSim 进行无人机群的仿真验证，使用 TCP/IP 中的 msgpack-rpc 协议完成 Python 程序与 AirSim 的通信，如图 26 所示。每次运行时指定一个端口号，AirSim 在仿真过程中会一直监听该端口的请求，Python 程序可以通过 msgpack 序列化格式向该端口发送 RPC 数据包，与 AirSim 进行交互控制。如此，AirSim 和 Python 程序可以相互隔离，互不干扰。此外，进行相应的端口号配置可以实现多机器仿真，一台机器运行 Python 程序，另外一台或多台机器运行 AirSim。

本文的无人机群对抗环境支持强化学习 VS 规则和强化学习 VS 强化学习两种方式。具体而言，环境提供的接口既可以输入单方无人机群的动作，

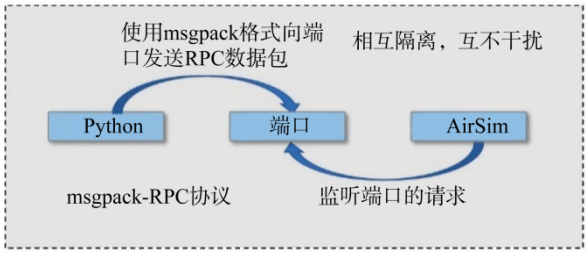


图 26 AirSim 和 Python 的通信机制

Fig. 26 Communication Mechanism between AirSim and Python

输出该方无人机群的观测、状态和奖励，又可以同时输入双方无人机群的动作，输出双方无人机群的观测、状态和奖励。

图 27 展示了本文代码仓库支持的两种训练方式：强化学习对抗手工规则（uni_runner）和强化学习自我对抗（bi_runner）。此外，代码框架适用主流攻击算法，如基于策略、状态、奖励函数的攻击，由 adv_runner 实现。基于少数群体和多数群体

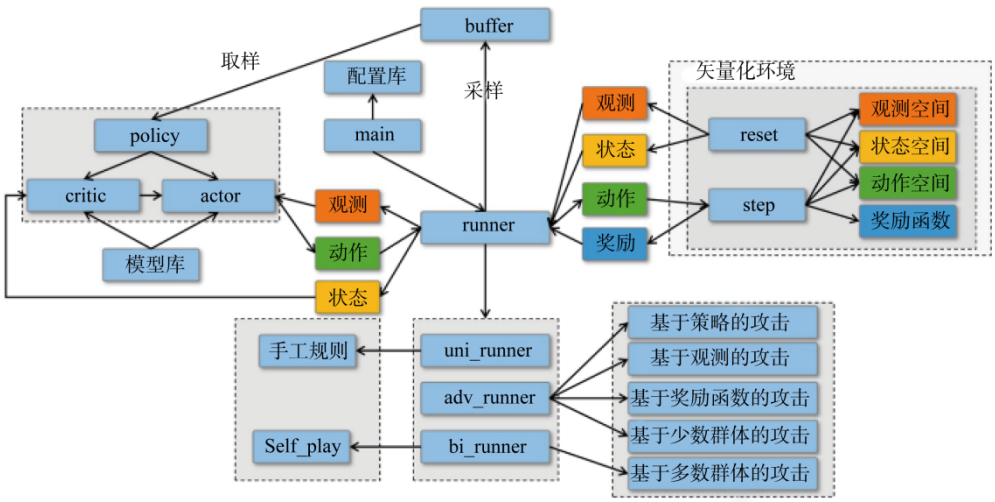


图 27 无人机群对抗平台的代码结构

Fig. 27 Code Structure of Drone Swarm Confrontation Platform

的攻击算法可复用 adv_runner 和 bi_runner。这 5 种攻击算法集成于算法库，附带相应模型库。通过选择或修改配置库中的配置文件，可统一训练和测试这些攻击算法。

需要强调的是，本框架实现的 MAPPO 算法不仅在模型性能上优越，训练效率也出色。由于 MAPPO 是策略算法，样本利用率低，需要大量样本。为此，本文利用 Python 的多线程通信，同时运行多个 AirSim 环境，各自与主线程通信完成采样，再传送样本至主线程用于无人机群模型训练。在有足够的硬件资源（CPU、内存、显卡）的情况下，可显著缩短训练时间。

4　结论

强化学习训练的无人机群模型已被广泛应用，但鲁棒性不足，易受攻击。当前多智能体环境中鲁棒性研究不足，本文基于 AirSim 创建了对抗环境并适配了多智能体算法，揭示了模型脆弱性。尽管本环境比其他仿真环境复杂，但与真实无人机群相比还有所简化，如忽略了无人机异构性、通信机制和物理环境。未来需考虑更多细节和防御方法，以加强模型的真实性和鲁棒性。

参考文献：

[1] MIKAYEL S, TABISH R, CHRISTIAN W, et al. The starcraft multi-agent challenge [J]. ArXiv Preprint ArXiv: 1902.04043, 2019.

[2] BEI P, TABISH R, CHRISTIAN S, et al. Facmac: factored multiagent centralised policy gradients [J]. Advances in Neural Information Processing Systems, 2021, 34: 12208-12221.

[3] XIA Z, DU J, WANG J, et al. Multi-agent reinforcement learning aided intelligent uav swarm for target tracking [J]. IEEE Transactions on Vehicular Technology, 2021, 71(1): 931-945.

[4] BALDAZO D, PARRAS J, ZAZO S. Decentralized multi-agent deep reinforcement learning in swarms of drones for flood monitoring [C] // 2019 27th European Signal Processing Conference (EUSIPCO). IEEE, 2019: 1-5.

[5] WU C, JU B, WU Y, et al. UAV autonomous target search based on deep reinforcement learning in complex disaster scene [J]. IEEE Access, 2019, 7: 117227-117245.

[6] CHUNG T. Offensive swarm-enabled tactics (offset) [J]. DARPA Tactical Technology Office Proposers Day, Arlington, VA, Accessed January, 2017, 30.

[7] KAUFMANN E, BAUERSFELD L, LOQUERCIO A, et al. Champion-level drone racing using deep reinforcement learning [J]. Nature, 2023, 620(7976): 982-987.

[8] GAO Y, DOAN B G, ZHANG Z, et al. Backdoor attacks and countermeasures on deep learning: A comprehensive review [J]. ArXiv Preprint ArXiv: 2007.10760, 2020.

[9] LIU Y, MA X, Bailey J, et al. Reflection backdoor: A natural backdoor attack on deep neural networks [C] // Computer Vision-ECCV 2020, 16th European Conference, Glasgow, UK, August, 23-28, 2020, Proceedings. Part X 16. Springer International Publishing, 2020: 182-199.

[10] SAHA A, SUBRAMANYA A, PIRSIAVASH H. Hidden trigger backdoor attacks [C] // Proceedings of the AAAI Conference on Artificial Intelligence, 2020, 34(07): 11957-11965.

[11] LIN J, DZEPAROSKA K, ZHANG S, et al. On the robustness of cooperative multi-agent reinforcement learning [C] // 2020 IEEE Security and Privacy Workshops (SPW). IEEE, 2020: 62-68.

[12] LIU A, GUO J, WANG J, et al. X-adv: Physical adversarial object attacks against x-ray prohibited item detection [J]. ArXiv Preprint ArXiv: 2302.09491, 2023.

[13] LI S, ZHANG S, CHEN G, et al. Towards benchmarking and assessing visual naturalness of physical world adversarial attacks [C] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 12324-12333.

[14] GUO J, LIU A, ZHENG X, et al. Isolation and induction: training robust deep neural networks against model stealing attacks [J]. ArXiv Preprint ArXiv: 2308.00958, 2023.

[15] ADAM G, MICHAEL D, CODY W, et al. Adversarial policies: attacking deep reinforcement learning [J].

ArXiv Preprint ArXiv: 1905.10615, 2019.

[16] SHITAL S, DEBADEEPTA D, CHRIS L, et al. Airsim: high-fidelity visual and physical simulation for autonomous vehicles [J]. Field and Service Robotics, 2018.

[17] LOWE R, WU Y, TAMAR A, et al. Multi-agent actor-critic for mixed cooperative- competitive environments [J]. Advances in Neural Information Processing Systems, 2017, 30.

[18] LILLICRAP T, HUNT J, PRITZEL A, et al. Continuous control with deep reinforcement learning [J]. ArXiv Preprint ArXiv: 1509.02971, 2015.

[19] CHAO Y, AKASH V, EUGENE V, et al. The surprising effectiveness of ppo in cooperative, multi-agent games [J]. ArXiv Preprint ArXiv: 2103.01955, 2021.

[20] JOHN S, FILIP W, PRAFULLA D, et al. Proximal policy optimization algorithms [J]. ArXiv Preprint ArXiv: 1707.06347, 2017.

[21] WU X, GUO W, WEI H, et al. Adversarial policy training against deep reinforcement learning [C] // USENIX Security Symposium. 2021: 1883-1900.

[22] GUO W, WU X, HUANG S, et al. Adversarial policy learning in two-player competitive games [C] // International Conference on Machine Learning. PMLR, 2021: 3910- 3919.

[23] HUANG S, PAPERNOT N, GOODFELLOW I, et al. Adversarial attacks on neural network policies [J]. ArXiv Preprint ArXiv: 1702.02284, 2017.

[24] LIN Y, HONG Z, LIAO Y, et al. Tactics of adversarial attack on deep reinforcement learning agents [J]. ArXiv Preprint ArXiv: 1703.06748, 2017.

[25] INKAWHICH M, CHEN Y, LI H. Snooping attacks on deep reinforcement learning [J]. ArXiv Preprint ArXiv: 1905.11832, 2019.

[26] BEHZADAN V, HSU W. Adversarial exploitation of policy imitation [J]. ArXiv Preprint ArXiv: 1906.01121, 2019.

[27] ZHANG X, MA Y, SINGLA A, et al. Adaptive reward-poisoning attacks against reinforcement learning [C] // International Conference on Machine Learning. PMLR, 2020: 11225-11234.

[28] LI S, GUO J, XIU J, et al. Attacking cooperative multi-agent reinforcement learning by adversarial minority influence [J]. ArXiv Preprint ArXiv: 2302.03322, 2023.

[29] TODOROV E, EREZ T, TASSA Y. Mujoco: A physics engine for model-based control [C] // 2012 IEEE/RSJ International Conference on Intelligent Robots and Systems. IEEE, 2012: 5026-5033.

[30] GOODFELLOW I, SHLENS J, SZEGEDY C. Explaining and harnessing adversarial examples [J]. ArXiv Preprint ArXiv: 1412.6572, 2014.

[31] MNIH V, KAVUKCUOGLU K, SILVER D, et al. Playing atari with deep reinforcement learning [J]. ArXiv Preprint ArXiv: 1312.5602, 2013.

[32] MNIH V, BADIA A, MIRZA M, et al. Asynchronous methods for deep reinforcement learning [C] // International Conference on Machine Learning. PMLR, 2016: 1928- 1937.

[33] BROCKMAN G, CHEUNG V, PETTERSSON L, et al. Openai gym [J]. ArXiv Preprint ArXiv: 1606.01540, 2016.

[34] LIN Y, HONG Z, LIAO Y, et al. Tactics of adversarial attack on deep reinforcement learning agents [J]. ArXiv Preprint ArXiv: 1703.06748, 2017.

[35] BEHZADAN V, HSU W. Adversarial exploitation of policy imitation [J]. ArXiv Preprint ArXiv: 1906.01121, 2019.

[36] ZHANG X, MA Y, SINGLA A, et al. Adaptive reward-poisoning attacks against reinforcement learning [C] // International Conference on Machine Learning. PMLR, 2020: 11225-11234.

[37] RASHID T, SAMVELYAN M, DE W, et al. Monotonic value function factorisation for deep multi-agent reinforcement learning [J]. The Journal of Machine Learning Research, 2020, 21(1): 7234-7284.

[38] MADRY A, MAKELOV A, SCHMIDT L, et al. Towards deep learning models resistant to adversarial attacks [J]. ArXiv Preprint ArXiv: 1706.06083, 2017.

[39] EVERITT T, KRAKOVNA V, ORSEAU L, et al. Reinforcement learning with a corrupted reward channel

[J]. ArXiv Preprint ArXiv：1705.08417，2017.

[40] HAN Y，RUBINSTEIN B I P，ABRAHAM T，et al. Reinforcement learning for autonomous defence in software-defined networking [C]// Decision and Game Theory for Security：9th International Conference，GameSec 2018，Seattle，WA，USA，October 29-31，2018，Proceedings 9. Springer International Publishing，2018：145-165.

[41] KIOURTI P，WARDEGA K，JHA S，et al. TrojDRL：evaluation of backdoor attacks on deep reinforcement learning [C]// 2020 57th ACM/IEEE Design Automation Conference（DAC）. IEEE，2020：1-6.